Математические методы распознавания образов, ВМК МГУ, Семинар №5 Примеры применения EM-алгоритма.

(основа взята из конспекта ФКН ВШЭ)

Брескану Никита

Март 2025

1 Основная идея EM-алгоритма

Пусть дана задача максимизации непрерывной функции

$$f(\theta) \to \max_{\theta}$$

Однако может оказаться, что задача невыпукла, и поэтому решать её сложно. Но возможно, если ввести новую переменную $q(\theta)$, то получится нижняя оценка, и $F(\theta, q)$ окажется выпукла по θ.

$$f(\theta) = F(\theta, q^*(\theta)) \geq F(\theta, q), \forall q$$

И тогда можно проводить поочерёдную оптимизацию:

1. $q \leftarrow \arg\max_q F(\theta, q) \quad (q \leftarrow q^*(\theta))$
2. $\theta \leftarrow \arg\max_\theta F(\theta, q)$

Соответсвенно, в задаче минимизиации это будет верхняя оценка вместо нижней.
Заметим, такой алгоритм гарантированно увеличивает значение $f(\theta)$ на каждой итерации:

$$f(\theta^{\text{new}}) = F(\theta^{\text{new}}, q^*(\theta^{\text{new}})) \geq F(\theta^{\text{new}}, q^*(\theta^{\text{old}})) \geq F(\theta^{\text{old}}, q^*(\theta^{\text{old}})) = f(\theta^{\text{old}})$$

Один из распространённых примеров верхней оценки является касательная выпуклой функции (1).

$$f(w) \geq f(\xi) + f'(\xi)(w - \xi)$$

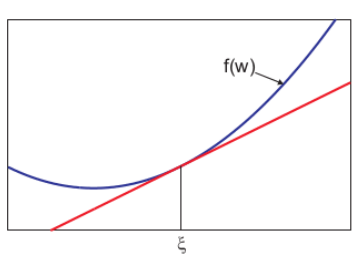

Рис. 1: Касательная выпуклой функции

Такая верхняя оценка используется, например, в вогнуто-выпуклой процедуре (ConCave-Convex Procedure или CCCP) [1].

Перейдём теперь непосредственно к EM-алгоритму. Дана сложная задача максимизации логарифма правдоподобия, которую мы по каким-то причинам (например, невыпуклость) не хотим решать обычными методами:

$$\log p(X|\theta) \to \max_{\theta}$$

Пусть в модели существуют скрытые переменные Z, описывающее её внутреннее состояние. Для некоторого распределения $q(Z)$ на скрытых переменных верно:

$$\begin{aligned}\log p(X|\theta) = \int q(Z) \log p(X|\theta) dZ = \\ \int q(Z) \log \frac{p(X,Z|\theta)}{p(Z|X,\theta)} dZ = \int q(Z) \log \frac{p(X,Z|\theta)q(Z)}{p(Z|X,\theta)q(Z)} dZ = \\ \int q(Z) \log \frac{p(X,Z|\theta)}{q(Z)} dZ + \int q(Z) \log \frac{q(Z)}{p(Z|X,\theta)} dZ = \\ \mathcal{L}(q,\theta) + \mathrm{KL}(q(Z)\|p(Z|X,\theta)).\end{aligned}$$

Так как KL дивергенция положительная, то получили нижнюю оценку:

$$\log p(X|\theta) \geq \mathcal{L}(q,\theta) = \mathbb{E}_{Z\sim q(Z)} \log \frac{p(X,Z|\theta)}{q(Z)}$$

Таким образом, мы ввели новую переменную $q(Z)$, принадлежащую классу вероятностных распределений над скрытыми переменными, которая обеспечивает нижнюю оценку.

При этом, если KL дивергенция зануляется, то получаем точное равенство, поэтому $(q^*(Z))(X,\theta) = p(Z|X,\theta)$. Отсюда, переходя к попеременной оптимизации, получаем классический EM-алгоритм:

EM алгоритм:

1. **E-step:** Вычисление апостериорного распределения на латентных переменных:

$$q^*(Z) \leftarrow p(Z|X,\theta)$$

2. **M-step:** Максимизация логарифма полного правдоподобия:

$$\theta \leftarrow \arg\max_{\theta} \mathbb{E}_{Z\sim q^*(Z)} \log p(X,Z|\theta)$$

2 Разделение смеси распределений Бернулли

Пусть есть L бинарных векторов размера D: $x_1, \ldots, x_L$, записанные матрицей $X \in \{0,1\}^{L\times D}$.

Перед нами стоит задача нечётко кластеризовать (soft clustering, т.е. объект может принадлежать сразу нескольким кластерам) эти бинарные векторы на K кластеров. Например, это может быть разделение пользователей на группы по бинарным признакам их интеракций с системой.

Рассмотрим смесь распределений Бернулли:

$$p(x|\mu,\pi) = \sum_{k=1}^{K} \pi_k p(x|\mu_k),$$

где $x \in \mathbb{R}^D$, $\mu = \{\mu_1, \ldots, \mu_K\}$, $\mu_k \in [0,1]^D$, $\pi = \{\pi_1, \ldots, \pi_K\}$, $\sum_{i=1}^K \pi_k = 1$, и

$$p(x_j|\mu_k) = \mu_{kj}^{x_j}(1-\mu_{kj})^{1-x_j},$$
$$p(x|\mu_k) = \prod_{j=1}^D \mu_{kj}^{x_j}(1-\mu_{kj})^{1-x_j}.$$

Иными словами, k-я компонента смеси — это такое распределение на D-мерных бинарных векторах, что j-я координата вектора имеет распределение Бернулли с параметром μ_{kj}.

Введём скрытые переменные z — категориальные случайные величины: z_{ik} показывает принадлежность i-ого объекта k-ому кластеру (0 или 1). Тогда вероятностная модель будет иметь вид:

$$p(X, Z|\theta) = \prod_{i=1}^L \prod_{k=1}^K \Big[\pi_k p(x_i|\mu_k)\Big]^{z_{ik}}$$

На E-шаге вычисляется апостериорное распределение на скрытых переменных:

$$p(Z|X, \theta^{\text{old}}) = \frac{p(X, Z|\theta^{\text{old}})}{p(X|\theta^{\text{old}})} = \frac{\prod_{i=1}^L \prod_{k=1}^K \Big[\pi_k^{\text{old}} p(x_i|\mu_k^{\text{old}})\Big]^{z_{ik}}}{\sum_Z \prod_{i=1}^L \prod_{k=1}^K \Big[\pi_k^{\text{old}} p(x_i|\mu_k^{\text{old}})\Big]^{z_{ik}}}$$

Заметим, что данное распределение факторизуется в произведение распределений, соответствующих отдельным объектам $p(z_i|x_i, \theta^{\text{old}})$:

$$p(Z|X, \theta^{\text{old}}) = \prod_{i=1}^L p(z_i|x_i, \theta^{\text{old}}) = \prod_{i=1}^L \frac{\prod_{k=1}^K \Big[\pi_k^{\text{old}} p(x_i|\mu_k^{\text{old}})\Big]^{z_{ik}}}{\sum_{k=1}^K \pi_k^{\text{old}} p(x_i|\mu_k^{\text{old}})},$$

Введём обозначение:

$$g_{ik} \equiv p(z_{ik} = 1|x_i, \theta^{\text{old}}) = \frac{\pi_k^{\text{old}} p(x_i|\mu_k^{\text{old}})}{\sum_{s=1}^K \pi_s^{\text{old}} p(x_i|\mu_s^{\text{old}})}.$$

Вычислим теперь матожидание полного правдоподобия:

$$\begin{aligned}
&\mathbb{E}_{Z\sim p(Z|X,\theta^{\text{old}})} \log p(X, Z|\theta) = \\
&\quad = \mathbb{E}_{Z\sim p(Z|X,\theta^{\text{old}})} \sum_{i=1}^L \sum_{k=1}^K z_{ik} \Big\{\log \pi_k + \log p(x_i|\mu_k)\Big\} = \\
&\quad = \sum_{i=1}^L \sum_{k=1}^K \mathbb{E}_{Z\sim p(Z|X,\theta^{\text{old}})}[z_{ik}] \Big\{\log \pi_k + \log p(x_i|\mu_k)\Big\}.
\end{aligned}$$

Нам понадобится вспомогательная величина:

$$\mathbb{E}_{Z\sim p(Z|X,\theta^{\text{old}})}[z_{ik}] = 1 * p(z_{ik} = 1|x_i, \theta^{\text{old}}) + 0 * p(z_{ik} = 0|x_i, \theta^{\text{old}}) = g_{ik}.$$

Получаем следующую оптимизационную задачу:

$$\mathbb{E}_{Z\sim p(Z|X,\theta^{\text{old}})} \log p(X, Z|\theta) = \sum_{i=1}^L \sum_{k=1}^K g_{ik} \Big\{\log \pi_k + \log p(x_i|\mu_k)\Big\} =$$
$$= \sum_{i=1}^L \sum_{k=1}^K g_{ik} \Big\{\log \pi_k + \sum_{j=1}^d (x_{ij} \log \mu_{kj} + (1-x_{ij}) \log(1-\mu_{kj}))\Big\} \to \max_{\{\pi_k, \mu_k\}}$$

Дифференцируя данный функционал, можем получить формулы М-шага:

$$\pi_k^{\text{new}} = \frac{1}{L}\sum_{i=1}^{L} g_{ik};$$
$$\mu_{kj}^{\text{new}} = \frac{\sum_i g_{ik} x_{ij}}{\sum_i g_{ik}}.$$

3 Восстановление разметки с помощью EM-алгоритма

В настоящее время все более популярны модели, требующие большого количества размеченных данных (например, нейронные сети). Однако разметка большой выборки для новой задачи является дорогостоящей процедурой. Сейчас существуют сервисы, где исполнители за небольшую плату могут размечать данные заказчика (например, отвечать, улыбается ли человек на приведенном изображении). Примерами таких сервисов являются Amazon Mechanical Turk и Яндекс.Толока.

Эксперты, размечающие данные, не заинтересованы в качественной разметке или не обладают достаточной компетенцией, поэтому результирующие данные получаются зашумленными, что может сильно сказаться на качестве итогового алгоритма. Основным способом борьбы с данным эффектом является усреднение ответов по нескольким экспертам, то есть простое голосование. У данного способа есть очевидные проблемы: он не учитывает (1) компетенцию каждого эксперта и (2) сложность решаемой задачи.

Рассмотрим датасет из L изображений задачи бинарной классификации, для которого собраны ответы экспертов $l_{ij} \in \{0, 1\}$, где l_{ij} — разметка i-го изображения j-ым экспертом (наблюдаемые переменные), а также известны истинные метки изображений $z_i \in \{0, 1\}$, то есть скрытые переменные, которые мы хотим восстановить. Дополнительно зададим параметры $\alpha_j \in (-\infty, +\infty)$ — уровень экспертизы j-ого экперта и $\beta_i \in (0, +\infty)$ такое, что $1/\beta_i$ представляет сложность i-ой задачи. Совместное распределение зададим следующим образом (l_i обозначает набор меток для i-ого изображения от всех экспертов):

$$p(z_i, l_i|\alpha, \beta_i) = p(z_i)\prod_j p(l_{ij}|z_i, \alpha_j, \beta_i)$$
$$p(l_{ij} = z_i|z_i, \alpha_j, \beta_i) = \sigma(\alpha_j\beta_i) = \frac{1}{1 + \exp(-\alpha_j\beta_i)},$$

Почему мы задаем параметры и совместное распределение именно так? Оказывается, что такая вероятностная модель обладает несколькими свойствами, логичными для нашей задачи. Если мы зафиксируем β_i и рассмотрим $\alpha_j \to +\infty$, то получим $p(l_{ij} = z_i|z_i, \alpha_j, \beta_i) \to 1$, то есть такой эксперт всегда решает правильно любую задачу конечной сложности. Аналогично, при $\alpha_j \to -\infty$ мы получаем $p(l_{ij} = z_i|z_i, \alpha_j, \beta_i) \to 0$, то есть получается очень вредный эксперт, который намеренно (или от путаницы) портит нам разметку.

Теперь посмотрим на величину $1/\beta_i$. Если $1/\beta_i \to 0$, то для "хорошего" эксперта ($\alpha_j > 0$) получаем $p(l_{ij} = z_i|z_i, \alpha_j, \beta_i) \to 1$, а для "плохого" ($\alpha_j < 0$) выходит $p(l_{ij} = z_i|z_i, \alpha_j, \beta_i) \to 0$. То есть любой эксперт легко идентифицирует правильный класс картинки и выдает разметку исходя из свой вредности. Напротив, при $1/\beta_i \to +\infty$ получаем вероятность $p(l_{ij} = z_i|z_i, \alpha_j, \beta_i) \to 1/2$ как для "хороших", так и для "плохих" экспертов. Авторы этой вероятностной модели назвали её GLAD (Generative model of Labels, Abilities and Difficulties) [2].

Оптимальные параметры α и β, а также распределение истинной разметки z_i мы будем искать с помощью EM-алгоритма. Но для начала обратим внимание на априорное распределение $p(z_i)$. Его можно оставить равномерным $p(z_i = 0) = p(z_i = 1) = 1/2$, а можно внести в него наши представления о балансе классов среди картинок. Еще один вариант - ввести параметр $\pi = p(z_i = 1)$ и вести оптимизацию по нему на М-шаге. Но мы оставим эту вероятность фиксированной.

Начнем вывод EM-алгоритма с того, что приведем вероятностную модель к более удобному виду. Мы бы хотели работать с величиной $p(l_{ij}|z_i, \alpha_j, \beta_i)$, но нам задана только $p(l_{ij} = z_i|z_i, \alpha_j, \beta_i)$. Для начала запишем следующее выражение:

$$p(l_{ij} \neq z_i|z_i, \alpha_j, \beta_i) = 1 - p(l_{ij} = z_i|z_i, \alpha_j, \beta_i) = 1 - \sigma(\alpha_j, \beta_i) = \sigma(-\alpha_j\beta_i)$$

Теперь мы можем перейти к записи с индикаторами:

$$\begin{aligned} p(l_{ij}|z_i, \alpha_j, \beta_i) &= p(l_{ij} = z_i|z_i, \alpha_j, \beta_i)^{[l_{ij}=z_i]} p(l_{ij} \neq z_i|z_i, \alpha_j, \beta_i)^{[l_{ij}\neq z_i]} = \\ &= \sigma(\alpha_j\beta_i)^{[l_{ij}=z_i]}\sigma(-\alpha_j\beta_i)^{[l_{ij}\neq z_i]} \end{aligned}$$

Соответственно, совместное распределение на наблюдаемые и латентные переменные выглядит так:

$$p(z_i, l_i|\alpha, \beta_i) = p(z_i) \prod_j \left(\sigma(\alpha_j\beta_i)^{[l_{ij}=z_i]}\sigma(-\alpha_j\beta_i)^{[l_{ij}\neq z_i]} \right)$$

Пришло время выписать формулу для E-шага алгоритма:

$$\begin{aligned} q_i^*(z_i) = p(z_i|l, \alpha, \beta) = p(z_i|l_i, \alpha, \beta_i) = \frac{p(z_i, l_i|\alpha, \beta_i)}{p(l_i|\alpha, \beta_i)} = \frac{p(z_i, l_i|\alpha, \beta_i)}{\sum_{z\in\{0,1\}} p(z, l_i|\alpha, \beta_i)} = \\ = \frac{p(z_i) \prod_j \left(\sigma(\alpha_j\beta_i)^{[l_{ij}=z_i]}\sigma(-\alpha_j\beta_i)^{[l_{ij}\neq z_i]} \right)}{\sum_{t\in\{0,1\}} p(t) \prod_j \left(\sigma(\alpha_j\beta_i)^{[l_{ij}=t]}\sigma(-\alpha_j\beta_i)^{[l_{ij}\neq t]} \right)} \end{aligned}$$

<u>*Замечание:*</u> Из соображений численной устойчивости на практике обычно считают логарифмы вероятности $\log p(t, l_i|\alpha, \beta_i)$, а затем применяют оператор Softmax:

$$\gamma_i^t = \log p(t, l_i|\alpha, \beta_i) = \log p(t) + \sum_j \left([l_{ij} = t] \log \sigma(\alpha_j\beta_i) + [l_{ij} \neq t] \log \sigma(-\alpha_j\beta_i) \right)$$

$$q_i^*(z_i) = \frac{\exp(\gamma_i^{z_i})}{\sum_{t\in\{0,1\}} \exp(\gamma_i^t)}$$

Вспомним, что на M-шаге нам нужно решить следующую оптимизационную задачу:

$$\mathbb{E}_{q^*} \log p(z, l|\alpha, \beta) \to \max_{\alpha,\beta}$$

Очень часто бывает так, что этот оптимум можно найти аналитически, для этого нужно приравнивять градиент матожидания к нулю и решить получившееся уравнение относительно α и β. Однако здесь нам не повезло, уравнение на градиент не решается аналитически, поэтому мы прибегнем к градиентным методам оптимизации. Для этого найдем градиент матожидания по α и β.

Для начала немного распишем само матожидание (все слагаемые, не зависящие от α и β мы уберем

в константу — все равно они никак не повлияют на градиент):

$$
\begin{aligned}
\mathbb{E}_{q^*} \log p(z, l|\alpha, \beta) &= \mathbb{E}_{q^*}\left[\log \prod_i p(z_i, l_i|\alpha, \beta_i)\right] = \mathbb{E}_{q^*}\left[\sum_i \log p(z_i, l_i|\alpha, \beta_i)\right] = \\
&= \sum_i \mathbb{E}_{q_i^*}\Big[\log p(z_i, l_i|\alpha, \beta_i)\Big] = \sum_i \mathbb{E}_{q_i^*}\left[\log\Big(p(z_i)\prod_j p(l_{ij}|z_i, \alpha_j, \beta_i)\Big)\right] = \\
&= \sum_i \left(\mathbb{E}_{q_i^*}\Big[\log p(z_i)\Big] + \sum_j \mathbb{E}_{q_i^*}\Big[\log p(l_{ij}|z_i, \alpha_j, \beta_i)\Big]\right) = \\
&= \sum_i \sum_j \mathbb{E}_{q_i^*}\Big[\log p(l_{ij}|z_i, \alpha_j, \beta_i)\Big] + \text{const} = \\
&= \sum_i \sum_j \sum_{t\in\{0,1\}} q_i^*(t) \log p(l_{ij}|t, \alpha_j, \beta_i) + \text{const} = \\
&= \sum_i \sum_j \sum_{t\in\{0,1\}} q_i^*(t)\Big([l_{ij} = t]\log\sigma(\alpha_j\beta_i) + [l_{ij} \neq t]\log\sigma(-\alpha_j\beta_i)\Big) + \text{const}
\end{aligned}
$$

Вычислим несколько вспомогательных производных:

$$
\frac{d}{dx}\log\sigma(x) = -\frac{d}{dx}\log(1+\exp(-x))) = \frac{\exp(-x)}{1+\exp(-x)} = \frac{1}{\exp(x)+1} = \sigma(-x)
$$

$$
\frac{\partial}{\partial\alpha_j}\log\sigma(\alpha_j\beta_i) = \beta_i\,\sigma(-\alpha_j\beta_i) \qquad \frac{\partial}{\partial\alpha_j}\log\sigma(-\alpha_j\beta_i) = -\beta_i\,\sigma(\alpha_j\beta_i)
$$

$$
\frac{\partial}{\partial\beta_i}\log\sigma(\alpha_j\beta_i) = \alpha_j\,\sigma(-\alpha_j\beta_i) \qquad \frac{\partial}{\partial\beta_i}\log\sigma(-\alpha_j\beta_i) = -\alpha_j\,\sigma(\alpha_j\beta_i)
$$

Осталось собрать все вместе:

$$
\frac{\partial}{\partial\alpha_j}\mathbb{E}_{q^*}\log p(z, l|\alpha, \beta) = \sum_i \sum_{t\in\{0,1\}} q_i^*(t)\beta_i\Big([l_{ij} = t]\sigma(-\alpha_j\beta_i) - [l_{ij} \neq t]\sigma(\alpha_j\beta_i)\Big)
$$

$$
\frac{\partial}{\partial\beta_i}\mathbb{E}_{q^*}\log p(z, l|\alpha, \beta) = \sum_j \sum_{t\in\{0,1\}} q_i^*(t)\alpha_j\Big([l_{ij} = t]\,\sigma(-\alpha_j\beta_i) - [l_{ij} \neq t]\sigma(\alpha_j\beta_i)\Big)
$$

Теперь, когда у нас есть доступ к градиенту по параметрам, мы можем оптимизировать матожидание с помощью градиентного подъема или даже какого-нибудь более продвинутого метода оптимизации. Однако на практике часто оказывается достаточно делать один или несколько шагов в сторону градиента, не дожидаясь полной сходимости, а затем снова переходить к E-шагу.

Список литературы

[1] Yuille, Alan L., and Anand Rangarajan. "The concave-convex procedure (CCCP)."Advances in neural information processing systems 14 (2001).

[2] *Whitehill, Jacob et al.* Whose vote should count more: Optimal integration of labels from labelers of unknown expertise. // Advances in neural information processing systems, 2009.