

# Тематическое моделирование

ВМК МГУ 2025 год

Елисова Анастасия

10 апреля 2025 г.

## 1 Введение

Тематическое моделирование в литературе описывается с точки зрения задачи кластеризации текстовых коллекций. Перед нами большая коллекция текстов: это могут быть миллионы документов. Хочется понять, какие темы есть в этих документах. Для начала определимся с тем что мы будем понимать под словом 'тема':

- тема — специальная терминология предметной области
- тема - набор часто совместно встречающихся терминов
- тема — семантически однородный кластер текстов

Более формально,

- тема — условное распределение на множестве терминов,  $p(w|t)$  — вероятность термина  $w$  в теме  $t$ ;
- тематический профиль документа - условное распределение  $p(t|d)$  - вероятность темы  $t$  в документе  $d$ .

То есть тема - просто частотный словарь на множестве слов (то, с какой частотой в этой теме появляется то или иное слово).

Например, тему по биологии от темы по математике мы отличаем по тому, с какой частотой употребляется специальная терминология в каждой теме. Второе, что нас будет интересовать - распределение по темам в каждом документе, и это то, что отличает задачу от классических задач кластеризации (говорят жесткая кластеризация и мягкая кластеризация). Кластеризация новостей - это очень популярная задача, и там, как правило, кластеризация жесткая, потому что новостное сообщение относится к какому-то событию или какой-то теме; если же говорить о кластеризации научных статей, то там кластеризация будет мягкой, потому что научная статья может относиться сразу к

нескольким темам: много исследований бывают на стыке наук, а значит, нужно научиться не только выделять темы как распределение над словами, но ещё и научиться выделять темы в каждом документе, понимать, что документ может быть связан с несколькими темами.

## 2 Исследование задачи

Пусть у нас есть три конечных множества:  $W$  - слова,  $D$  - документы и  $T$  - темы. Предполагаем, что вся коллекция текстовых документов - это последовательность таких троек. Тематическая модель выявляет латентные темы по наблюдаемым распределениям слов  $p(w|d)$  в документах. Когда автор писал термин  $w$  в документе  $d$ , он думал о теме  $t$ , и мы хотели бы выявить, о какой именно. По формуле полной вероятности:

$$p(w|d) = \sum_{t \in T} p(w|t)p(t|d)$$

(Здесь пользуемся гипотезой условной независимости:  $p(w|d, t) = p(w|t)$ , так как предполагаем, что порождение слов в документе не зависит от самого документа, а только от темы)

Будем решать задачу восстановления  $p(w|t)$  и  $p(t|d)$  по коллекции.

Дано: Коллекция текстовых документов:

- $n_{dw}$  — частоты терминов в документах
- Эмпирическое распределение терминов:

$$\hat{p}(w|d) = \frac{n_{dw}}{n_d}, \quad \text{где } n_d = \sum_w n_{dw}$$

Найти: Параметры тематической модели:

$$p(w|d) = \sum_{t \in T} \phi_{wt} \theta_{td}$$

где:

- $\phi_{wt} = p(w|t)$  — распределение терминов в теме
- $\theta_{td} = p(t|d)$  — распределение тем в документе

Математическая формулировка: Задача представляет собой *стохастическое матричное разложение* (стохастическое, т.к. столбцы всех трех матриц - векторы, соответствующие дискретным вероятностным распределениям: каждый столбец нормирован, сумма элементов равна единице и не отрицательна):

$$\hat{P} \approx \Phi \Theta$$

- $\hat{\mathbf{P}} = [\hat{p}(w|d)]$  — матрица эмпирических распределений (термины  $\times$  документы)
- $\Phi = [\phi_{wt}]$  — матрица тем (термины  $\times$  темы)
- $\Theta = [\theta_{td}]$  — матрица распределений тем (темы  $\times$  документы)

Чтобы строить вероятностные модели, можно воспользоваться методом максимума правдоподобия.

Правдоподобие - плотность распределения выборки  $(d_i, w_i)_{i=1}^n$  :

$$\prod_{i=1}^n p(d_i, w_i) \prod_{d \in D} \prod_{w \in d} p(d, w)^{n_{dw}}$$

Максимизация логарифма правдоподобия

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln p(w|d) p(d) \rightarrow \max_{\Theta, \Phi}$$

приводит к задаче математического программирования:

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} \rightarrow \max_{\Theta, \Phi}$$

при ограничениях неотрицательности и нормировки

$\phi_{wt} \geq 0$ ;  $\sum_{w \in W} \phi_{wt} = 1$ ;  $\theta_{td} \geq 0$ ;  $\sum_{t \in T} \theta_{td} = 1$ ;,  $n$  означает суммарную длину всей коллекции.

Плохая новость про эту задачу - она некорректно поставлена по Адамару: ее решение не единственное (точнее, существует бесконечное множество решений этой задачи). Мы ищем матричное разложение, которое определено с точностью до невырожденного преобразования.

Если  $(\Phi, \Theta)$  — решение, то для любой стохастической матрицы  $S$  размера  $|T| \times |T|$  пара  $(\Phi', \Theta')$  также является решением:  $\Phi' = \Phi S$ ,  $\Theta' = S^{-1} \Theta$

При этом выполняется:  $\Phi' \Theta' = (\Phi S)(S^{-1} \Theta) = \Phi \Theta$

Сохраняется значение функционала правдоподобия:  $\mathcal{L}(\Phi', \Theta') = \mathcal{L}(\Phi, \Theta)$

Для приближённых решений:  $\mathcal{L}(\Phi', \Theta') \geq \mathcal{L}(\Phi, \Theta) - \varepsilon$ .

Нужно применить регуляризацию, то есть сказать, какими ещё дополнительными критериями хотелось бы, чтобы обладали матрицы  $\Phi$  и  $\Theta$ , чтобы найти единственное устойчивое решение.

Максимизация логарифма правдоподобия с регуляризатором:

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} + R(\Theta, \Phi) \rightarrow \max_{\Theta, \Phi}, R(\Theta, \Phi) = \sum_i \tau_i R_i(\Theta, \Phi)$$

(Можем взять несколько регуляризаторов и сложить эти критерии с какими-то весовыми коэффициентами)

Покажем, что наша задача - ЕМ-алгоритм (метод простой итерации для системы уравнений), где

Е-шаг:

$$p_{tdw} \equiv p(t|d, w) = \text{norm}_{t \in T}(\phi_{wt}\theta_{td})$$

М-шаг:

$$\begin{aligned}\phi_{wt} &= \text{norm}_{w \in W}(n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}}), n_{wt} = \sum_{d \in D} n_{dw} p_{tdw} \\ \theta_{td} &= \text{norm}_{t \in T}(n_{td} + \theta_{td} \frac{\partial R}{\partial \theta_{td}}), n_{td} = \sum_{w \in d} n_{dw} p_{tdw},\end{aligned}$$

где  $\text{norm}_{t \in T}(x_t) = \frac{\max(x_t, 0)}{\sum_{s \in T} \max(x_s, 0)}$  - операция нормировки вектора.

Решение может быть вырожденным для некоторых тем (столбцов матриц  $\Phi$ ) и документов (столбцов матрицы  $\Theta$ ).

Тема  $t$  вырождена, если для всех терминов  $w \in W$

$$n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \leq 0.$$

Если тема  $t$  вырождена, то  $p(w|t) = \phi_{wt} \equiv 0$ ; это означает, что тема исключается из модели (происходит отбор тем).

Документ  $d$  вырожден, если для всех тем  $t \in T$

$$n_{td} + \theta_{td} \frac{\partial R}{\partial \theta_{td}} \leq 0.$$

Если документ  $d$  вырожден, то  $p(t|d) = \theta_{td} \equiv 0$ ; это означает, что модель не в состоянии описать данный документ.

Приведём доказательство корректности постановки такой задачи с помощью теоремы Каруша-Куна-Таккера.

Задача математического программирования:

$$\begin{cases} f(x) \rightarrow \min_x; \\ g_i(x) \leq 0, i = 1, \dots, m; \\ h_j(x) = 0, j = 1, \dots, k; \end{cases}$$

Необходимые условия:

Если  $x$  - точка локального минимума, то существуют множители  $\mu_i, i = 1, \dots, m, j = 1, \dots, k$ :

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x} = 0, \mathcal{L}(x; \mu, \lambda) = f(x) + \sum_{i=1}^m \mu_i g_i(x) + \sum_{j=1}^k \lambda_j h_j(x); \\ g_i(x) \leq 0, h_j(x) = 0; \text{ (исходные ограничения)} \\ \mu_i \geq 0; \text{ (двойственные ограничения)} \\ \mu_i g_i(x) = 0; \text{ (условие дополняющей нежёсткости)} \end{cases}$$

Вывод системы уравнений из условий Каруша-Куна-Таккера

1. Условия ККТ для  $\phi_{wt}$  (для  $\theta_{td}$  всё аналогично):

$$\sum_d n_{dw} \frac{\theta_{td}}{p(w|d)} + \frac{\partial R}{\partial \phi_{wt}} = \lambda_t - \mu_{wt}; \quad \mu_{wt} \geq 0; \quad \mu_{wt} \phi_{wt} = 0.$$

2. Умножим обе части равенства на  $\phi_{wt}$  и выделим  $p_{tdw}$ :

$$\phi_{wt} \lambda_t = \sum_d n_{dw} \frac{\phi_{wt} \theta_{td}}{p(w|d)} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} = n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}}.$$

3. Если  $\lambda_t \leq 0$ , то тема  $t$  вырождена,  $\phi_{wt} = 0$  для всех  $w$ .

4. Если  $\lambda_t > 0$ , то либо  $\phi_{wt} = 0$ , либо  $n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} > 0$ :

$$\phi_{wt} \lambda_t = \left( n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \right)_+.$$

5. Суммируем обе части равенства по  $w \in W$ :

$$\lambda_t = \sum_{w \in W} \left( n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \right)_+.$$

6. Подставим  $\lambda_t$  из (5) в (4), получим требуемое.

ЕМ-алгоритм — это чередование Е и М шагов до сходимости.

- **Е-шаг:** условные вероятности тем  $p(t|d, w)$  для всех  $t, d, w$  вычисляются через  $\phi_{wt}$ ,  $\theta_{td}$  по формуле Байеса:

$$p(t|d, w) = \frac{p(w, t|d)}{p(w|d)} = \frac{p(w|t)p(t|d)}{p(w|d)} = \frac{\phi_{wt}\theta_{td}}{\sum_s \phi_{ws}\theta_{sd}}.$$

- **М-шаг:** при  $R = 0$  частотные оценки условных вероятностей вычисляются суммированием счётчика  $n_{tdw} = n_{dw}p(t|d, w)$ :

$$\begin{aligned} \phi_{wt} &= \frac{n_{wt}}{n_t}, \quad n_{wt} = \sum_{d \in D} n_{tdw}, \quad n_t = \sum_{w \in W} n_{wt}; \\ \theta_{td} &= \frac{n_{td}}{n_d}, \quad n_{td} = \sum_{w \in d} n_{tdw}, \quad n_d = \sum_{t \in T} n_{td}. \end{aligned}$$

Построение матрицы  $X \in \mathbb{R}^{D \times W}$ , где  $D$  — число документов,  $W$  — размер словаря; нахождение с помощью сингулярного разложения лучшей аппроксимации (в смысле квадратичного отклонения) ранга  $T$ :

$$X = \Theta\Phi, \quad \Theta \in \mathbb{R}^{D \times T}, \quad \Phi \in \mathbb{R}^{T \times W}.$$

будет называться **Latent semantic analysis (LSA)**.

Рассмотрим далее несколько известных моделей.

### 3 Probabilistic latent semantic analysis (PLSA)

Будем считать, что каждый документ  $x_d$  описывается распределением  $p(t|d) = \theta_{td}$ , а каждая тема — распределением  $p(w|t) = \phi_{wt}$ . Тогда совместное распределение на словах и документах можно записать как

$$p(w, d) = p(d)p(w|d) = p(d) \sum_{t=1}^T p(w|t)p(t|d).$$

Здесь мы, по сути, ввели скрытую переменную  $t$ , которая показывает, из какой темы было сгенерировано слово  $w$  документа  $x_d$ . Согласно данной модели, документ  $x_d$  генерируется по следующей схеме:

1. Выбираем тему  $t \sim p(t|d)$ ;
2. Выбираем слово из данной темы  $w \sim p(w|t)$ ;
3. Повторяем шаги 1 и 2, если текст не достиг требуемой длины.

Чтобы записать правдоподобие, следует смотреть на набор документов как на выборку пар «документ-слово». Неполное правдоподобие данной модели имеет вид

$$\sum_{d=1}^D \sum_{j=1}^{|x_d|} \log \sum_{t=1}^T \phi_{w_{dj}t} \theta_{td},$$

где  $w_{dj}$  —  $j$ -е по порядку слово из документа  $x_d$ . Если для каждой пары «документ-слово»  $(d, w_{dj})$  известно, из какой темы  $t_{dj}$  оно сгенерировано, то можно записать полное правдоподобие:

$$\sum_{d=1}^D \sum_{j=1}^{|x_d|} \sum_{t=1}^T [t_{dj} = t] \log \phi_{w_{dj}t} \theta_{td}.$$

Мы уже знаем, что для обучения таких моделей можно воспользоваться ЕМ-алгоритмом. На Е-шаге оценим апостериорные распределения на скрытых переменных по формуле Байеса:

$$p(t_{dj}|d, w_{dj}) = \frac{p(w_{dj}|t_{dj})p(t_{dj}|d)}{p(w_{dj}|d)} = \frac{\phi_{w_{dj}t_{dj}}\theta_{t_{dj}d}}{p(w_{dj}|d)}$$

На М-шаге найдём максимум матожидания полного правдоподобия по скрытым переменным:

$$\phi_{wt} = \frac{\sum_{d=1}^D n_{dw} p(t|d, w)}{\sum_{w=1}^W \sum_{d=1}^D n_{dw} p(t|d, w)};$$

$$\theta_{td} = \frac{\sum_{w=1}^W n_{dw} p(t|d, w)}{\sum_{t=1}^T \sum_{w=1}^W n_{dw} p(t|d, w)}.$$

Здесь  $n_{dw}$  — число вхождений слова  $w$  в документ  $x_d$ .

Полученная в итоге работы ЕМ-алгоритма модель будет интерпретируемой — можно изучать, насколько сильно та или иная тема представлена в документе, или насколько то или иное слово характерно для темы.

С точки зрения введения регуляризации можно заметить, что  $R(\Phi, \Theta) = 0$ , и на М-шаге происходит нормировка по  $w$  и  $t$  соответственно:

$$\phi_{wt} = \text{norm}_w(n_{wt})$$

$$\theta_{td} = \text{norm}_t(n_{td})$$

## Недостатки PLSA

- Переобучение модели:
  - Число параметров растёт как  $O(|D| \cdot |T| + |W| \cdot |T|)$
  - Слишком большая ёмкость модели приводит к переобучению
- Отсутствие контроля разреженности:
  - Если  $\phi_{wt} = 0$  на инициализации, то  $\phi_{wt} = 0$  и в финальной модели
  - Аналогично для  $\theta_{td}$ :  $\theta_{td} = 0 \Rightarrow \theta_{td} = 0$  в результате
- Проблема новых слов:
  - Для слов с нулевой частотой:  $n_w = 0 \Rightarrow \hat{p}(w|d) = 0$  для всех  $t \in T$
  - Невозможность корректной оценки вероятности неизвестных слов

## 4 Latent Dirichlet Allocation (LDA)

Модель PLSA не является полной — распределения  $\phi_t$  и  $\theta_d$  считаются параметрами, не предполагается, что они тоже генерируются из некоторых распределений. Значит, с помощью данной модели не получится описать процесс порождения набора документов «с

нуля». Более того, в PLSA отсутствует регуляризация, из-за чего модель может слишком сильно подогнаться под данные на небольших выборках.

Чтобы устранить два указанных недостатка, введём априорные распределения на векторах  $\phi_t$  и  $\theta_d$ . Для этого хорошо подходит симметричное распределение Дирихле, которое задано на множестве всех дискретных распределений с фиксированным числом исходов.

Пусть вектор-столбцы параметров модели:  $\phi_t = (\phi_{wt})_{w \in W}$  и  $\theta_d = (\theta_{td})_{t \in T}$  - генерируются распределениями Дирихле с параметрами  $\alpha \in \mathbb{R}^{|T|}$  и  $\beta \in \mathbb{R}^{|W|}$ :

Плотность распределения Дирихле для вектора слов в теме:

$$\text{Dir}(\phi_t|\beta) = \frac{\Gamma(\beta_0)}{\prod_{w \in W} \Gamma(\beta_w)} \prod_{w \in W} \phi_{wt}^{\beta_w - 1},$$

где  $\phi_{wt} > 0$  для всех  $w \in W$ ,  $\beta_0 = \sum_{w \in W} \beta_w$ ,  $\beta_w > 0$  для всех  $w \in W$ .

Плотность распределения Дирихле для вектора тем в документе:

$$\text{Dir}(\theta_d|\alpha) = \frac{\Gamma(\alpha_0)}{\prod_{t \in T} \Gamma(\alpha_t)} \prod_{t \in T} \theta_{td}^{\alpha_t - 1},$$

где  $\theta_{td} > 0$  для всех  $t \in T$ ,  $\alpha_0 = \sum_{t \in T} \alpha_t$ ,  $\alpha_t > 0$  для всех  $t \in T$ .

Совместное правдоподобие данных и параметров модели:

$$\ln \prod_{d \in D} \prod_{w \in d} p(w, d|\Phi, \Theta)^{n_{dw}} \prod_{t \in T} \text{Dir}(\phi_t|\beta) \prod_{d \in D} \text{Dir}(\theta_d|\alpha) \rightarrow \max_{\Phi, \Theta}$$

Логарифм априорного распределения выступает в качестве регуляризатора:

$$R(\Phi, \Theta) = \sum_{t \in T} \sum_{w \in W} (\beta_w - 1) \ln \phi_{wt} + \sum_{d \in D} \sum_{t \in T} (\alpha_t - 1) \ln \theta_{td}$$

М-шаг — сглаженные (или разреженные) частотные оценки:

$$\phi_{wt} = \text{norm}_w(n_{wt} + \beta_w - 1) \tag{1}$$

$$\theta_{td} = \text{norm}_t(n_{td} + \alpha_t - 1) \tag{2}$$

- При  $\beta_w > 1$ ,  $\alpha_t > 1$  – эффект сглаживания распределений
- При  $0 < \beta_w < 1$ ,  $0 < \alpha_t < 1$  – слабое разреживание распределений
- При  $\beta_w = 1$ ,  $\alpha_t = 1$  – априорное распределение становится равномерным (вырожденный случай PLSA)



Полезным свойством является то, что распределение Дирихле способно порождать как сильно разреженные распределения, так и сильно сконцентрированные. После введения априорного распределения модель становится достаточно сложной для вывода. Как правило, для её обучения применяют техники вариационного вывода или семплирование Гиббса.

Почему именно распределение Дирихле?

- Оно способно порождать разреженные векторы,
- Имеет параметры, управляющие степенью разреженности,
- Описывает кластерные структуры на симплексе,
- Математически удобно для байесовского вывода.

## Недостатки Latent Dirichlet Allocation

- Проблемы теоретического обоснования:
  - Слабые лингвистические основания выбора именно распределения Дирихле
  - Эвристический характер предположения  $p(\phi_t|\beta) = \text{Dir}(\beta)$
- Вычислительная сложность:
  - Оригинальный метод требует интегрирования по пространству параметров:

$$p(w|d) = \int \int p(w|\phi)p(\phi|\beta)p(\theta|\alpha)d\phi d\theta$$

- Необходимость использования приближённых методов (VB, MCMC)
- Проблемы регуляризации:
  - По умолчанию реализует сглаживание ( $\beta_w > 1$ )
  - Для разреживания ( $\beta_w < 1$ ) требуется специальная настройка
- Эмпирические ограничения:
  - На больших корпусах разница с PLSA статистически незначима:

$$\Delta\mathcal{L} = \mathcal{L}_{LDA} - \mathcal{L}_{PLSA} \approx 0 \quad \text{при } |D| \rightarrow \infty$$

## 5 Оценивание качества

### Правдоподобие и перплексия (perplexity)

Правдоподобие языковой модели  $p(w|d)$  (чем выше, тем лучше):

$$\mathcal{L}(\Phi, \Theta) = \sum_{d \in D} \sum_{w \in d} n_{dw} \ln p(w|d), \quad p(w|d) = \sum_t \phi_{wt} \theta_{td}$$

Перплексия языковой модели  $p(w|d)$  (чем меньше, тем лучше):

$$P(D) = \exp \left( -\frac{1}{n} \sum_{d \in D} \sum_{w \in d} n_{dw} \ln p(w|d) \right), \quad n = \sum_{d \in D} \sum_{w \in d} n_{dw}$$

Интерпретация перплексии:

- если распределение  $p(w|d) = \frac{1}{|W|}$  равномерное, то  $P = |W|$
- мера различности или неопределённости слов в тексте
- коэффициент ветвления (branching factor) текста

### Перплексия тестовой коллекции $D'$ (hold-out perplexity)

$$P(D') = \exp \left( -\frac{1}{n''} \sum_{d \in D'} \sum_{w \in d''} n_{dw} \ln p(w|d) \right), \quad n'' = \sum_{d \in D'} \sum_{w \in d''} n_{dw}$$

$d = d' \cup d''$  — случайное разбиение тестового документа на две половины равной длины;

Параметры  $\phi_{wt}$  оцениваются по обучающей коллекции  $D$ ;

Параметры  $\theta_{td}$  оцениваются по первой половине  $d'$ ;

Перплексия вычисляется по второй половине  $d''$ .

### Интерпретируемость тем

Тема считается **интерпретируемой**, если по топовым словам темы эксперт может определить, о чём эта тема, и дать ей название.

Методы оценки интерпретируемости:

- **Экспертные оценки:**
  - интерпретируемость темы по балльной шкале
  - каждую тему оценивают несколько экспертов
- **Метод интрузий (intrusion):**
  - в список топовых слов внедряется лишнее слово
  - измеряется доля ошибок экспертов при его определении

Автоматическая мера интерпретируемости

Требуется автоматически вычисляемая мера интерпретируемости, коррелирующая с экспертными оценками.

Такой мерой оказалась *когерентность* (согласованность, *coherence*).

**Когерентность (согласованность) темы  $t$  по  $k$  топовым словам**

$$PMI_t = \frac{2}{k(k-1)} \sum_{i=1}^{k-1} \sum_{j=i+1}^k PMI(w_i, w_j)$$

где  $w_i$  —  $i$ -й термин в порядке убывания  $\phi_{wt}$ .

$$PMI(u, v) = \ln \frac{|D|N_{uv}}{N_u N_v} \quad (\text{поточечная взаимная информация, pointwise mutual information})$$

- $N_{uv}$  — число документов, в которых термины  $u, v$  хотя бы один раз встречаются рядом (в окне 10 слов)
- $N_u$  — число документов, в которых  $u$  встретился хотя бы 1 раз
- $|D|$  — общее количество документов в коллекции

## Список литературы

- [1] Лекция К.В. Воронцова по тематическому моделированию
- [2] Семинар Соколова Е.А.
- [3] Воронцов К. В., Потапенко А. А. Модификации ЕМ-алгоритма для вероятностного тематического моделирования. Машинное обучение и анализ данных. — 2013
- [4] Тематическое моделирование