

Спектральная кластеризация. Оценка качества кластеризации

Е. А. Соколов, А. Гусев, И. Садртдинов, А. Качура

1 Спектральная кластеризация

Спектральная кластеризация основывается на применении спектральной теории графов к задаче кластеризации объектов выборки. Метод можно кратко описать последовательностью шагов:

1. Построение по выборке графа с вершинами, соответствующими элементам этой выборки.
2. Вычисление координат вершин графа в пространстве, задаваемом собственными векторами лапласиана.
3. Кластеризация вершин.

1.1 Построение графа

На данном шаге по выборке $X = (x_1, \dots, x_n)$, $x_i \in \mathbb{R}^D$, которую мы будем для удобства считать упорядоченной последовательностью арифметических векторов, строится неориентированный взвешенный граф $G = (V, E, W)$, где $V = (v_1, \dots, v_n)$ — набор вершин, E — набор рёбер, W — набор весов рёбер.


Рассмотрим несколько вариантов задания рёбер в таком графе:

1. Граф G может быть полным с ребрами, вес которых определяется по некоторой формуле, например:


$$w_{i,j} = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

Гиперпараметр σ определяет, насколько нам важны далекие объекты.


2. G можно задать как kNN-граф, то есть объект x_i будет связан с k его ближайшими соседями. Веса всех рёбер принимаются равными 1.
3. Вершина x_i может быть связана с теми вершинами, расстояние до которых меньше выбранного ε , то есть $\rho(x_i, x_j) < \varepsilon$. Такой граф будет называться ε -графом. Веса всех рёбер принимаются равными 1.



Полный взвешенный
граф



2-NN граф



ε -граф

1.2 Вычисление координат вершин графа

На данном шаге требуется найти набор координатных функций $f_k : V \rightarrow \mathbb{R}$, $k = 1, \dots, m$ для некоторого натурального $m \leq n$ (то есть таких функций, что $f_k(i)$ принимается за k -ую координату точки x_i в новом пространстве), которые являются оптимальными в некотором смысле. Решение будет получено при помощи собственных векторов лапласиана графа.

Определим для произвольного функционала $f : V \rightarrow \mathbb{R}$ оператор градиента по правилу

$$(\text{grad } f)(i, j) = f(j) - f(i),$$

а для произвольного функционала $g : V \times V \rightarrow \mathbb{R}$ такого, что $g(i, j) = -g(j, i)$ для $\{i, j\} \in E$ и $g(i, j) = 0$ для $\{i, j\} \notin E$ — оператор дивергенции по правилу

$$(\operatorname{div} g)(i) = \sum_{j=1}^n w_{i,j} g(i, j).$$

Лапласианом графа называется оператор

$$L = -\operatorname{div} \operatorname{grad}.$$

Подставив в эту формулу определения градиента и дивергенции, получим

$$\begin{aligned} (Lf)(i) &= (-\operatorname{div} \operatorname{grad} f)(i) = \sum_{j=1}^n w_{i,j} (f(i) - f(j)) = \\ &= \left(\sum_{j=1}^n w_{i,j} \right) f(i) - \sum_{j=1}^n w_{i,j} f(j) = d_i f(i) - \sum_{j=1}^n w_{i,j} f(j), \end{aligned}$$

где $d_i = \sum_{j=1}^n w_{i,j}$ то есть $L = D - W$, $D = \operatorname{diag}(d_1, \dots, d_n)$.

Рассмотрим несколько свойств лапласиана L :

Утверждение 1.

Пусть $f \in \mathbb{R}^n$. Тогда имеет место следующая формула:

$$f^T L f = \frac{1}{2} \sum_{i,j=1}^n w_{i,j} (f_i - f_j)^2$$

Доказательство.

$$\begin{aligned}
f^\top L f &= f^\top D f - f^\top W f = \sum_{i=1}^n d_i f_i^2 - \sum_{i,j=1}^n w_{i,j} f_i f_j = \\
&= \sum_{i=1}^n \left(\sum_{j=1}^n w_{i,j} \right) f_i^2 - \sum_{i,j=1}^n w_{i,j} f_i f_j = \sum_{i,j=1}^n w_{i,j} f_i^2 - \sum_{i,j=1}^n w_{i,j} f_i f_j = \\
&= \frac{1}{2} \sum_{i,j=1}^n w_{i,j} f_i^2 + \frac{1}{2} \sum_{i,j=1}^n w_{i,j} f_i^2 - \sum_{i,j=1}^n w_{i,j} f_i f_j = \\
&= \frac{1}{2} \sum_{i,j=1}^n w_{i,j} f_i^2 + \frac{1}{2} \sum_{i,j=1}^n w_{i,j} f_j^2 - \sum_{i,j=1}^n w_{i,j} f_i f_j = \\
&= \frac{1}{2} \sum_{i,j=1}^n w_{i,j} (f_i^2 - 2f_i f_j + f_j^2) = \frac{1}{2} \sum_{i,j=1}^n w_{i,j} (f_i - f_j)^2
\end{aligned}$$

□

Утверждение 2. L — симметричная неотрицательно определенная матрица.

Доказательство.

- *Симметричность:* $w_{i,j} = w_{j,i}$, так как граф неориентированный, то есть $W = W^\top$, а $D = D^\top$, так как диагональная; следовательно, $L^\top = D^\top - W^\top = D - W = L$.
- *Неотрицательная определённости:* согласно утверждению 1, $\forall f \in \mathbb{R}^n$ $f^\top L f = \frac{1}{2} \sum_{i,j=1}^n w_{i,j} (f_i - f_j)^2$. Выражение в правой части неотрицательно в силу неотрицательности весов рёбер.

□

Утверждение 3. Пусть L — лапласиан графа G . Тогда выполнены следующие два пункта:

1. Собственное значение $\lambda = 0$ матрицы L имеет геометрическую кратность, равную числу компонент связности K .
2. Пусть $A_1, \dots, A_K$ — компоненты связности графа G . Тогда векторы $f_1, \dots, f_K$, определяемые по формуле $f_k = ([x_i \in A_k])_{i=1}^n$, будут являться собственными векторами для $\lambda = 0$.

Доказательство. Сперва рассмотрим случай $K = 1$. Выясним, почему $\lambda = 0$ вообще является собственным значением матрицы L . Для этого рассмотрим вектор $f = (1, \dots, 1)$:

$$\begin{aligned} Lf &= Df - Wf = \begin{pmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{pmatrix} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} - \begin{pmatrix} w_{1,1} & w_{1,2} & \cdots & w_{1,n} \\ w_{2,1} & w_{2,2} & \cdots & w_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n,1} & w_{n,2} & \cdots & w_{n,n} \end{pmatrix} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \\ &= \begin{pmatrix} d_1 \\ \vdots \\ d_n \end{pmatrix} - \begin{pmatrix} w_{1,1} + \cdots + w_{1,n} \\ \vdots \\ w_{n,1} + \cdots + w_{n,n} \end{pmatrix} = 0 \end{aligned}$$

Теперь предположим, что существует собственный вектор $f' \in \mathbb{R}^n$: $\exists p \neq q \rightarrow f'_p \neq f'_q$, то есть неконстантный вектор, соответствующий $\lambda = 0$. Тогда $Lf' = 0 \Rightarrow f'^\top Lf' = 0$. Но рассматриваемый граф является связным. Значит существует путь $p = i_0 \rightarrow i_1 \rightarrow \cdots \rightarrow i_{t-1} \rightarrow i_t = q$. Поскольку вершины i_r и i_{r+1} соединены ребром, то $w_{i_r, i_{r+1}} > 0$, а значит, $f'_{i_r} = f'_{i_{r+1}}$ (иначе $f'^\top Lf' = \frac{1}{2} \sum_{i,j=1}^n w_{i,j} (f'_i - f'_j)^2 \geq \frac{1}{2} (w_{i_r, i_{r+1}} (f'_{i_r} - f'_{i_{r+1}})^2 + w_{i_{r+1}, i_r} (f'_{i_{r+1}} - f'_{i_r})^2) = w_{i_r, i_{r+1}} (f'_{i_r} - f'_{i_{r+1}})^2 > 0$). Отсюда $f'_p = f'_{i_1} = \cdots = f'_{i_{n-1}} = f'_q$ — константный вектор. Получили противоречие $\Rightarrow f'$ не является собственным вектором для $\lambda = 0$. Значит, мы доказали оба пункта для $K = 1$.

Пусть теперь $K > 1$. Можно упорядочить вершины так, чтобы лапласиан L стал блочно-диагональной матрицей:

$$L = \begin{pmatrix} L_1 & 0 & \cdots & 0 \\ 0 & L_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & L_K \end{pmatrix}$$

Блоки $L_1, \dots, L_K$ будут являться лапласианами компонент связности графа $G \Rightarrow \lambda = 0$ имеет геометрическую кратность K , а собственные векторы $f_1, \dots, f_K$ задаются по формуле

$$f_k = ([x_i \in A_k])_{i=1}^n$$

□

Выясним теперь, как при помощи лапласина графа построить оптимальные координатные функции для его вершин.

Попробуем для начала спроецировать вершины графа на прямую, то есть рассмотрим случай $m = 1$ с единственной координатной функцией $f \in \mathbb{R}^n$. Будем искать вектор f , минимизирующий функционал $\frac{1}{2} \sum_{i,j=1}^n w_{i,j} (f_i - f_j)^2 = f^\top L f$. Суть такого выбора объясняется тем, что данный функционал штрафует сильнее расстояния между парами близких точек (x_i, x_j) , то есть имеющих большое значение $w_{i,j}$. Решение поставленной задачи оптимизации неединственно. Поэтому введём на него два ограничения:

1. $f^\top f = 1$. Данное ограничение выступает в качестве нормировки длины вектора f .
2. $f^\top \mathbf{1} = 0$. Данное ограничение позволяет избавиться от тривиального решения $f = \mathbf{1}$, схлопывающего все точки в одну (предполагается, что граф связный).

Решением задачи оптимизации только с первым ограничением является вектор, соответствующий минимальному собственному значению L (то есть 0). Добавление второго ограничения избавляет от решения, соответствующего нулевому собственному значению. Таким образом, решением задачи оптимизации с двумя введёнными ограничениями является вектор, соответствующий минимальному положительному собственному значению L .

Обратимся теперь к случаю $m \geq 2$. Будем минимизировать функционал $\frac{1}{2} \sum_{i,j=1}^n w_{i,j} \|(f_1(i), \dots, f_m(i)) - (f_1(j), \dots, f_m(j))\|^2 = \frac{1}{2} \text{tr}(F^\top L F)$, где $F = (f_1 | \dots | f_m) \in \mathbb{R}^{n \times m}$. В качестве ограничения будем использовать уравнение $F^\top F = I$, исключающее возможность проецирования выборки на подпространство размерности меньше $m - 1$. Можно показать, что решением такой задачи будет набор собственных векторов L , соответствующих m наименьшим собственным значениям.

Гипотеза 1. Пусть есть похожие объекты x_j и x_k , то есть расстояние между ними невелико. Тогда у собственных векторов f_i , соответствующих маленьким собственным значениям, выполнено $f_i(j) \approx f_i(k)$.

Эта гипотеза имеет лишь эмпирическое доказательство. Однако алгоритм, построенный на этой гипотезе, позволяет достигать успеха в задаче кластеризации. Данный алгоритм называется *спектральной кластеризацией*.

1.3 Связь спектральной кластеризации с разрезом графа

Определение 1.1. Разрезом (A, B) графа $G = (V, E)$ называется разбиение вершин этого графа на 2 непересекающихся множества (A, B) : $V = A \cup B, A \cap B = \emptyset$.

Определение 1.2. Стоимостью $c(A, B)$ разреза (A, B) называется величина $c(A, B) = \sum_{u \in A, v \in B} w_{u,v}$.

Рассмотрим задачу минимизации функционала

$$\text{Rcut}(A_1, \dots, A_K) = \frac{1}{2} \sum_{k=1}^K \frac{c(A_k, \bar{A}_k)}{|A_k|},$$

где $\bar{A}_k = V \setminus A_k$, по всем разбиениям множества вершин $V = A_1 \sqcup \dots \sqcup A_K$.

Заметим, что $c(A_k, \bar{A}_k) = f_k^\top L f_k$, где $f_k = ([x_i \in A_k]_{i=1}^n)$ и $|A_k| = \|f_k\|^2$. Поэтому

$$\text{Rcut}(A_1, \dots, A_K) = \sum_{k=1}^K \frac{f_k^\top}{\|f_k\|} L \frac{f_k}{\|f_k\|} = \sum_{k=1}^K \frac{f_k^\top L f_k}{f_k^\top f_k}.$$

Следовательно, задача минимизации Rcut эквивалентна задаче

$$\text{tr}(F^\top L F) \rightarrow \min, F = [f_1 | \dots | f_K] \in \mathbb{R}^{n \times K} : F^\top F = I, f_k \propto u_k \in \{0, 1\}^n, k = \overline{1, K}.$$

Данная задача минимизации является задачей дискретной оптимизации и принадлежит классу NP-сложных задач. Рассмотрим теперь задачу, полученную из исходной в результате непрерывной релаксации:

$$\text{tr}(F^\top L F) \rightarrow \min_{F=[f_1 | \dots | f_K] \in \mathbb{R}^{n \times K} : F^\top F = I},$$

В ней отброшено ограничение на пропорциональность $f_k, k = \overline{1, K}$, индикаторным векторам. Решением такой задачи является набор собственных векторов лапласиана L , соответствующих его K наименьшим собственным значениям.

1.4 Вычислительная сложность

Алгоритм спектральной кластеризации: *Сложность шага*

1. Строим по объектам граф G и лапласиан $L = D - W$. $\mathcal{O}(n^2)$
2. Находим нормированные собственные векторы $f_1, \dots, f_m$ матрицы L ,
соответствующие m наименьшим собственным значениям. $\mathcal{O}(n^3)$
3. Составляем матрицу $F \in \mathbb{R}^{n \times m}$: $F = (f_1 | \dots | f_m)$. $\mathcal{O}(nm)$
4. Обучаем на этой матрице алгоритм К-Means с K кластерами.
 $\mathcal{O}(l^{mK+1})$

Если мы верим в нашу гипотезу, то для похожих объектов соответствующие координаты векторов $f_1, \dots, f_m$ будут близки. Матрица F имеет размерность $n \times m$, поэтому можно посмотреть на неё, как на матрицу объекты-признаки. При этом новыми признаками будут как раз собственные вектора $f_1, \dots, f_m$. В описанном выше алгоритме предлагается обучать на них К-Means, но никто не запрещает использовать эти признаки для других задач.

Как видно, алгоритм обладает высокой вычислительной сложностью. Но утверждается, что он позволяет достигать впечатляющих результатов в задаче кластеризации. Однако как оценить, насколько хорошо алгоритм справляется с задачей классификации? Этому вопросу посвящён остаток занятия.

2 Оценка качества кластеризации

2.1 Метрика на разметке

Пусть существует разметка $(y_1, \dots, y_l)$, не участвующая при обучении. Мы не использовали эту разметку в качестве дополнительного признака, так как нам не хочется мотивировать модель данным признаком. Тогда предлагается ввести оценку качества алгоритма кластеризации при помощи этой разметки, саму же разметку тогда называют *gold standard*. Введем несколько требований к внешней метрике качества Q :

1. *Гомогенность*. Базовое свойство разделения разных объектов в разные кластеры:

$$Q \left(\begin{array}{|c|c|c|} \hline & \diamond & \diamond \\ \hline \times & & \diamond \\ \hline \times & \times & \\ \hline \end{array} \right) < Q \left(\begin{array}{|c|c|c|} \hline & \diamond & \diamond \\ \hline \times & & \diamond \\ \hline \times & \times & \\ \hline \end{array} \right)$$

2. *Полнота*. Один кластер не должен дробиться на несколько маленьких:

$$Q \left(\begin{array}{|c|c|c|} \hline & \times & \times \\ \hline \times & & \times \\ \hline \times & \times & \\ \hline \end{array} \right) < Q \left(\begin{array}{|c|c|c|} \hline & \times & \times \\ \hline \times & & \times \\ \hline \times & \times & \\ \hline \end{array} \right)$$

3. *Rag-bag*. Весь мусор должен быть в одном "мусорном" кластере, чтобы остальные кластеры были "чистыми":

$$Q \left(\begin{array}{|c|c|c|c|} \hline \times & \times & \bullet & \circ \\ \hline \times & \times & \triangleright & \star \\ \hline \times & * & \odot & \square \\ \hline \end{array} \right) < Q \left(\begin{array}{|c|c|c|c|} \hline \times & \times & \bullet & \circ \\ \hline \times & \times & \triangleright & \star \\ \hline \times & * & \odot & \square \\ \hline \end{array} \right)$$

4. *Cluster size vs. quantity*. Лучше испортить один кластер с целью улучшить качество множества других:

$$Q \left(\begin{array}{|c|c|c|c|} \hline \times & \circ & \circ \\ \hline \times & \star & \star \\ \hline \times & \triangleright & \triangleright \\ \hline \times & \odot & \odot \\ \hline \end{array} \right) < Q \left(\begin{array}{|c|c|c|c|} \hline \times & \circ & \circ \\ \hline \times & \star & \star \\ \hline \times & \triangleright & \triangleright \\ \hline \times & \odot & \odot \\ \hline \end{array} \right)$$

2.2 BCubed

Единственной известной на данный момент метрикой, обладающей всеми четырьмя названными свойствами является BCubed. Она считается следующим способом. Пусть $L(x)$ — gold standard, $C(x)$ — номер кластера, выдаваемый рассматриваемым алгоритмом. Тогда рассмотрим несколько величин:


$$\text{Correctness}(x, x') = \begin{cases} 1 & , C(x) = C(x') \wedge L(x) = L(x') \\ 0 & , \text{otherwise} \end{cases}$$

$$\text{Precision-BCubed} = \text{Avg}_x \left[\text{Avg}_{x': C(x)=C(x')} \text{Correctness}(x, x') \right]$$

$$\text{Recall-BCubed} = \text{Avg}_x \left[\text{Avg}_{x': L(x)=L(x')} \text{Correctness}(x, x') \right]$$

Тогда F-мера от определенных точности и полноты будет удовлетворять всем нужным нам требованиям.

Пример 1.



$$\text{Precision-BCubed} = 1, \text{Recall-BCubed} = \frac{1}{2}, \text{BCubed} = \frac{1 \cdot \frac{1}{2}}{1 + \frac{1}{2}} = \frac{1}{3}$$